$\boxed{NLP}$ Прямая/плоскость/гиперплоскость

Регрессия: приближ к Y

Классиф: разделить X так чтоб Y совпали

Логист. регр

Получаем число → $\geq$ порог $\xrightarrow{да} 1$

$\xrightarrow{нет} 0$

$$y = \begin{cases} 1, & \text{if } p(a + b_1 \cdot f_1(x) + b_2 \cdot f_2(x) + \ldots + b_n f_n(x)) \\ 0, & \text{else} \end{cases}$$

Вычисл. вер-ть принадл к классу

Обучение:

ф-ция правдоподобия - хотим увел

||

плотность вер-ти совместного появл. рез-тов в выборке

$$L = p(y_1|\theta) \cdot p(y_2|\theta) \ldots \cdot p(y_k|\theta)$$

Чтобы не умнож. а складывать делаем Log

$$L^* = \ln(L(y_1, y_2, \ldots y_n)) \longrightarrow \max$$

||

$$\sum_{k=1}^{k} [y_k \ln(p_k) + (1 - y_k) \cdot \ln(1 - p_k)]$$

алг оптимиз

$L^* \xrightarrow[\theta]{} \max$, $\theta = (a, b_1, \ldots, b_n)$

$$P_k = \frac{1}{1+e^{-a - b_1 f_1(x_k) - \ldots - b_n f_n(x_k)}}$$

— это метод градиентного подъема

Градиент:

$$\nabla L^*(\theta) = \frac{\partial L^*}{\partial \theta} = \left(\frac{\partial L^*}{\partial a}, \frac{\partial L^*}{\partial b_1}, \ldots, \frac{\partial L^*}{\partial b_n}\right)$$

начин. со случ знач

Шаг: → новые знач. коэфф θ

$$\theta^{[j+1]} = \theta^{[j]} + \alpha^{[j]} \nabla L^*(\theta^{[j]})$$

↑ длина шага в направл. град.

в-р

→ проверить условие остановки

$\nabla L^*(\theta^{[j+1]}) \le \varepsilon$ то $\theta = \theta^{[j+1]}$

↙ да → нашли

↓ нет

α лучше менять в разные моменты обучения

↳ задача оптимизации одном по α

зная вектор ∇

какой шаг сделать?

$$\Theta^{[j+1]} + \alpha^{[j]} \cdot \nabla L^*(\Theta^{[j]}) \xrightarrow[\alpha^{[j]}]{} \max$$

Представим что

L* это что-то типа парабол

для к-го мы уже знаем направл

Имея параболу на 3х точках

$\alpha_1 = 0.1$
0.001
0.0001

например тех можем постр параболу и найти ее экстремум

Но никто не гарантир. что мы взяли оптим точки

Метод Брейдя / Брента

Делаем несколько шагов до тех пор пока параметр. не станет хорошей (?)

Numeric

m Science
m. C

Нашли все параметры к-ые max L^*

Но если мы идеально это сделаем то получим overfitting

Потеряем способн. к обобщ

↓

она есть если качество работы на тестовой выборке не сильно отличается от того что на train

?: независим. test или нет

↓ если да то предполагаем сдвиг данных

↓ надеемся что test не реальные данные не сильно отличается от train данных

По-хорошему test должен быть размечен руками

Inferreal Methods in NLP → написал статью про последние советы

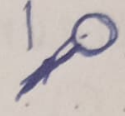

program of thoughts

~~danny birkin~~ git audioaugmentator
dangrebenkin

Переобучение избегать

→ Early stopping

train / val + test

после n итераций считаем L^* на val

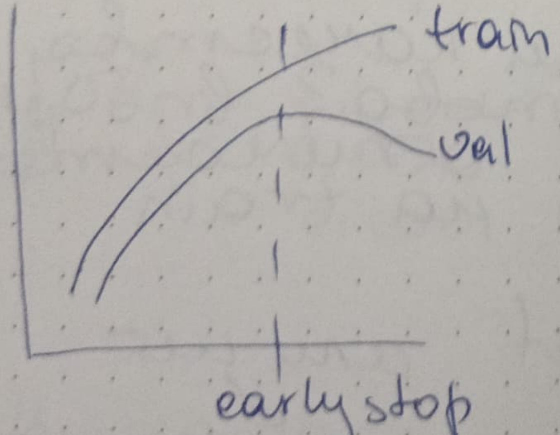

early stop time где начали faex

Не оптимиз. до момента когда L^* на val достигла max → дальше будет падать

→ 7. Кросс - валидация

один и тот же диктор не должен встречаться и в train и в val и вообще не должны в test

В train более старая дата, в test более новая

↓ или однокоренные слова

Анализ кач-ва бинарной классиф

TP, TN, FN, FP → Accuracy $= \frac{TP+FN}{TP+TN+FP+FN}$

Recall $= \frac{TP}{TP+FN}$

Precision $= \frac{TP}{TP+FP}$

Баланс типов ошибок

Чувствит $= \frac{TP}{TP+FN} \cdot 100\%$

доля TP к общему числу P примеров в обуч выборке

Специфичность $= \frac{TN}{TN+FP} \cdot 100\%$

насколько хорошо отклоняет N

В одно число хотелось бы

ROC кривая

$$y = \begin{cases} 1, & \dfrac{1}{1+e^{a+b_1 f_1(x)+\dots+b_n f_n(x)}} \geq th \\ 0, & \text{else} \end{cases}$$

перебирая порога будем изучать, пары или кривую

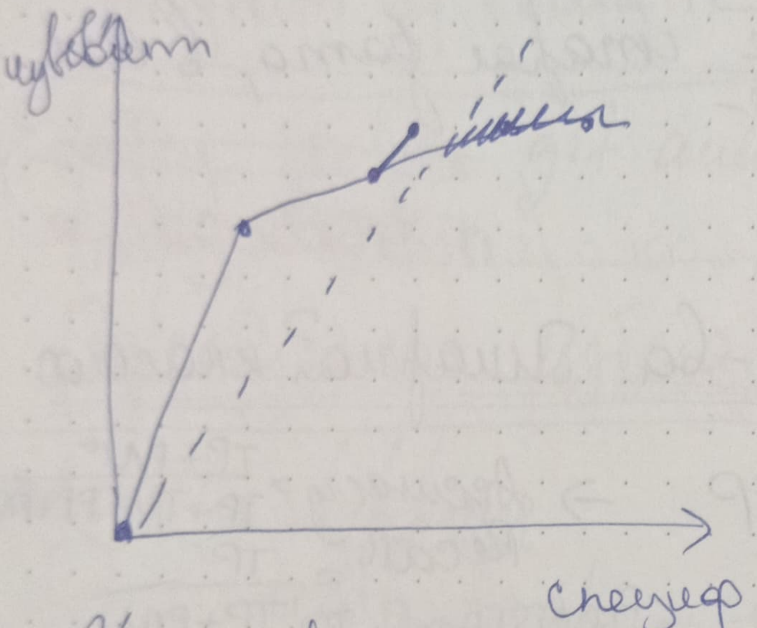

Чем круче эта кривая – чем больше площадь под ней тем лучше наш алгоритм работает независимо от порога

Если по пунктиру. ниже – все плохо

Если ниже нее – так не бывает – чтото в алг. ошибка

Многоклассовая

рассматрив как n бинарных классиф. и усредним рез-т

Точность и полнота

$$\text{Precision} = \frac{TP}{TP+FP} \cdot 100\%$$ не подмешали ли одних примеров

$$\text{Recall} = \frac{TP}{TP+FN} \cdot 100\%$$ не забыли ли какието P примеры

К одному числу → F-мера

$$F = \frac{(\beta^2+1)\,\text{Precision}\,\text{Recall}}{\beta\,\text{Precision} + \text{Recall}}$$

$\beta > 1$ → больше полнота

$0 < \beta < 1$ → больше точность

$\beta = 1$ → сбалансировано

это F1

Многоклассовая —//—

Про усреднение

1. TP_i, FP_i, FN_i для $\forall$ класса
2. Два способа

Макро уср

Что брать?

→ Если test сбалансир по классам, все равно

→ дисбаланс

хотим более точно учесть распозн редких
↓
macro

на частотные класс больше внимания
↓
micro

Нормализация данных

Разные размеры шкал данных

$$\begin{pmatrix} x_1(1) & & x_n(1) & y_1 \\ x_1(2) & \ddots & x_n(2) & y_2 \\ \vdots & & \vdots & \vdots \\ x_1(k) & & x_n(k) & y_k \end{pmatrix}$$

std - среднеквадр отклонение

mean - мат ожид

$$\downarrow$$

$$\begin{pmatrix} \frac{x_1(1)-x_1(mean)}{x_1(std)} & \cdots & \frac{x_n(1)-x_n(mean)}{x_n(std)} & y_1 \\ \vdots & \ddots & \vdots & \vdots \\ \frac{x_1(k)-x_1(mean)}{x_1(std} & \cdots & \frac{x_n(k)-x_n(mean)}{x_n(std]} & y_k \end{pmatrix}$$

TF, IDF и нормализ

огромный словарь
в ∀ тексте только малая часть этих слов
→ разреж знач

↳ спец: представл: позиции и значения ненул. эл-тов
scipy sparce

а если мы посчитаем мат ожидание то потеряем разреженность
↳ использ MaxAbsScaler
для ∀ призн находим максим и не упела

Но могут быть выбросы
Если исп MAxAbsScaler напрямую то отнормир по значен. выбросов
↳ RobustScaler нормал с учет аномальн. отре-

делаем квантильный диапазон и так нормирует

Мб делать не early stop а штрафовать за сложность?

↳ Регуляризация

штраф за большие веса

Параметр C опред. нам важн. градиент. сил-я (C>1) или штраф. модель за сложность (0< C<1)

Ridge regression

$$L^*(\theta) = C \cdot \frac{1}{K} \sum_{k=1}^{K} \left[y_k \ln(P_k) + (1-y_k) \ln(1-P_k) \right]$$
$$- \frac{1}{2} \sum_{i=1}^{n} b_i^2$$

низкоразм плотные вектора

Lasso regression

высокоразм разреж. вектора

$$L^*(\theta) = C \frac{1}{K} \sum_{k=1}^{K} \left[y_k \ln(P_k) + (1-y_k) \ln(1-P_k) \right] \cdot$$
$$\cdot \ln(1-P_k)$$

В глуб. нейросетях лучше исп. dropout